

Identificación:	Inteligencia Artificial. Trabajo Práctico 5. Tema. IA conexionista
Competencias	<ul style="list-style-type: none"> • CE1: Especificar, proyectar y desarrollar sistemas de información, sistemas de comunicación de datos y software cuya utilización pueda afectar la seguridad, salud, bienes o derechos. • CGT: Identificación, formulación y resolución de problemas de informática. / Utilización de técnicas y herramientas de aplicación en la informática • CGS: Fundamentos para el desempeño en equipos de trabajo. / CGS2 Fundamentos para la comunicación efectiva. / CGS3 Fundamentos para la acción ética y responsable. / CGS4 Fundamentos para evaluar y actuar en relación con el impacto social de su actividad en el contexto global y local / CGS5 Fundamentos para el aprendizaje continuo.
Resultado/s de Aprendizaje involucrado/s	<p>RA 1 Interpreta los principios teóricos y metodológicos de la Inteligencia Artificial para modelizar y resolver problemas de la ciencia de la computación o informática, o diversos dominios del contexto aplicando las definiciones correspondientes de forma eficiente según los recursos disponibles</p> <p>RA 2. Desarrolla proyectos con métodos y técnicas de la IA para modelizar y resolver problemas de las ciencias de la computación o informática, o diversos dominios del contexto, utilizando las definiciones correspondientes, validando la solución con software simulador de la IA, proponiendo experimentos y analizando e interpretando los hallazgos de forma eficiente según los recursos disponibles de acuerdo a los fundamentos teóricos - metodológicos de la tecnología IA elegida</p> <p>RA 3. Resuelve problemas abstraídos de la ciencias de la computación o informática, o diversos dominios del contexto con criterios de eficacia y eficiencia, realizando trabajos prácticos y actividades experimentales, elaborando y exponiendo los informes, empleando los métodos, técnicas y herramientas apropiadas de las tecnologías de IA para establecer relaciones y síntesis orientado a la toma de decisiones, contemplando el trabajo en equipo, las cuestiones éticas y buenas prácticas sociales y profesionales, de acuerdo a los fundamentos teóricos - metodológicos de la tecnología IA elegida</p>
Objetivos	<ul style="list-style-type: none"> • Adquirir principios teóricos y metodológicos de algunas tecnologías de la IA no simbólica
Modalidad de Trabajo	<ul style="list-style-type: none"> • Grupal (3 / 4 integrantes)
Estrategias de enseñanza	<ul style="list-style-type: none"> • Aprendizaje orientado a la indagación, Aprendizaje orientado a problemas
Herramienta (s) tecnología (s)	<ul style="list-style-type: none"> • Plataforma UNNE-Virtual, aula de la asignatura • Repositorios institucionales, bibliotecas virtuales, hemeroteca. • Herramientas interactiva, simuladores
Criterios de evaluación	<ul style="list-style-type: none"> • Participación en clases, presentación en tiempo y formato establecido. Participación en el coloquio todos los integrantes del equipo • Interpretación de consignas y resultados, fundamentación de respuestas • Evaluación en proceso, sumativa y formativa • Observación
Fecha de Entrega	<ul style="list-style-type: none"> • Puesta en común de resultados preliminares: 27/05,

Trabajo Práctico 5

Tema.

- Construcción y validación de un artefacto representativo de la IA no simbólica – integrando conocimientos y metodologías, utilizando las herramientas software apropiadas y aplicando el vocabulario específico- como propuesta de resolución de un problema abstraído de la realidad.

Actividades

- Conformar equipos de trabajo.
- Construir modelos de RNA - mínimo 3-
- Analizar los resultados. Proponer la mejor solución. Argumentar.
- Elaborar una infografía, que mencione: objetivo del estudio, las fases del método, workflow o pipeline, y una tabla resumen de los resultados.
- Exponer el trabajo práctico realizado por el equipo.

Trabajo Práctico 5

Planteamiento

- Seleccionar el conjunto de datos TITANIC/IRIS para desarrollar un modelo de RNA de clasificación. Ej. Repositorio: UCI Machine Learning Repository
- Determinar, el tipo de aprendizaje para el tratamiento de los datos según sea la solución de problema planteada.
- Métodos para construir modelos de RNA. Mencionar metodología/pipeline aplicada/adaptada en la construcción del modelo RNA, y su relación con el preprocesamiento / procesamiento / posprocesamiento,.
- Reconocer fundamentos teóricos del modelo de RNA elegido y del algoritmo seleccionado para el entrenamiento.
- Preprocesamiento. Aplicar técnica de balanceo: Over-Sampling / Under-Sampling / Otras técnicas asociadas al pre-procesamiento de datos.
- Procesamiento. Construir un modelo de RNA.
 - Dividir el conjunto de datos en dos o tres particiones: training, test, validación
 - Diseñar diferentes modelos de RNA [más de 1 modelo]. Por ej.: variar número de capas, número de neuronas en capas, funciones de activación, valores de otros hiperparámetros.
 - Época de entrenamiento/training epochs: número de iteraciones durante el entrenamiento.
 - Intervalo iteraciones. Establecer número de iteraciones en que se almacena el estado del entrenamiento.
 - Tasa / Ratio de aprendizaje: lambda que determina la velocidad o lentitud de modificación de los pesos durante el entrenamiento.
 - Tiempo de ejecución: que transcurre en realizarse el entrenamiento de la red, evaluación de las instancias de entrada y predicción del modelo.
 - Otros parámetros / hiperparámetros disponibles según herramienta de programación / experimentación seleccionada.
 - Ejecutar el entrenamiento, procesar el modelo,
- Posprocesar el modelo
 - Aplicar métricas para medir el desempeño de los resultados obtenidos en cada una de los modelos.
 - Realizar la evaluación. Determinar el modelo más adecuado. Argumentar la decisión.

En las siguientes diapositivas, se presentan algunos ejemplos de presentación de los resultados.
El texto Fuente, indica el acceso a los documentos seleccionados.

Trabajo Práctico 5

Ejemplos de presentación de resultados

Los resultados encontrados con la técnica de redes neuronales artificiales (RNA) arrojaron que esta técnica tiene un mejor pronóstico de evaluación y de clasificación que la obtenida por las técnicas ADM y Logit como se muestra en la [Tabla 6](#).

Tabla 6. Resumen de la matriz de precisión en clasificación del Desempeño Financiero de las empresas del Sector Comercial para la BMV, en la que compara las metodologías ADM, Logit y RNA para el periodo de 1990-2011.

Modelo	Precisión en la clasificación del Desempeño Financiero de las empresas		Total de aceptabilidad en la evaluación del desempeño
	Exitosa	No exitosa	
ADM*	81.38%	51.45%	66.80%
Logit*	80.30%	54.0%	68.80%
RNA	90.44 %	91.67%	91.15%

Fuente: García (2015) y Morales (2015). Basada en los resultados obtenidos del entrenamiento de la RNA Neuronal Multilayer Perceptron (NMLP) con arquitectura 6: 12: 2

Como se puede apreciar en la [tabla 6](#)., el modelo neuronal mejora la capacidad de predicción y clasificación en la determinación del desempeño de las empresas de la Bolsa Mexicana de Valores.

[Fuente: Desempeño financiero de las empresas: una propuesta de clasificación por rna¹](#)

Trabajo Práctico 5

Ejemplos de presentación de resultados

La [Tabla 5](#) presenta un comparativo general de los resultados de las métricas analizadas, se puede observar que la RNA-MLP es el modelo que registra los mejores resultados. Considerando que la desviación estándar (σ^2) de las métricas analizadas en cada uno de los modelos es cercana a cero, es decir, no se alejan entre sí, la Media (\bar{x}) es la Medida de Tendencia Central (MTC) más adecuada para analizar hacia donde se tienden a concentrar los datos. Se puede apreciar que todas las métricas obtenidas por la RNA son superiores a la Media (\bar{x}), lo que indica una vez más que es el modelo más adecuado para predecir el rendimiento académico de los estudiantes.

	<i>Naive Bayes</i>	<i>Regresión Logística</i>	<i>SVM</i>	<i>KNN</i>	<i>Random Forests</i>	<i>Árboles de Decisión</i>	<i>RNA</i>	<i>Media (\bar{x})</i>	<i>Desviación Estándar (σ^2)</i>
Accuracy	0,68	0,69	0,71	0,67	0,71	0,69	0,73	0,70	0,02
F1-Score	0,69	0,70	0,72	0,68	0,72	0,68	0,74	0,70	0,02
Recall	0,68	0,71	0,73	0,67	0,72	0,69	0,74	0,71	0,03
Precision	0,68	0,71	0,73	0,67	0,72	0,69	0,74	0,71	0,03

[Fuente: Predicción del rendimiento académico estudiantil con redes neuronales artificiales](#)

Trabajo Práctico 5

Ejemplos de presentación de resultados

Preguntas: En el cuadro 2:

- Mencione las columnas que corresponden a la configuración del modelo y cuales columnas a las métricas de evaluación
- Mencione el número de conjuntos de datos identificados

Los resultados experimentales de la búsqueda completa por rejilla se presentan en los [Cuadros 2](#) al [5](#). En el [Cuadro 2](#) se puede observar que la exactitud en el conjunto de prueba se encuentra en el intervalo de 0.61 a 0.97, y que en los tratamientos (1 al 10) la arquitectura LeNet5 con optimizador RMSProp y tasa de aprendizaje 1×10^{-4} es la de mejor desempeño, con una exactitud de 0.97.

Cuadro 2 Rendimiento en clasificación de los tratamientos con LeNet5 entrenada desde cero.

Hiperparámetros de entrenamiento					Rendimiento en clasificación		
Trat.	Optimizador	Tasa de aprendizaje	Pesos iniciales	Épocas	Exactitud entrenamiento	Exactitud validación	Exactitud prueba
1	RMSProp	1.0×10^{-3}	Random	21	0.90	0.66	0.61
2	RMSProp	1.0×10^{-4}	Random	44	0.99	0.98	0.97
3	RMSProp	1.0×10^{-5}	Random	174	0.98	0.94	0.94
4	RMSProp	1.5×10^{-5}	Random	131	0.96	0.94	0.92
5	RMSProp	1.0×10^{-6}	Random	226	0.94	0.88	0.87
6	Adam	1.0×10^{-3}	Random	15	0.70	0.58	0.62
7	Adam	1.0×10^{-4}	Random	36	0.99	0.96	0.95
8	Adam	1.0×10^{-5}	Random	65	0.96	0.90	0.89
9	Adam	1.5×10^{-5}	Random	64	0.97	0.94	0.93
10	Adam	1.0×10^{-6}	Random	247	0.95	0.91	0.92

Trat: Tratamiento.

[Fuente: Clasificación de manzanas con redes neuronales convolucionales](#)